

InsightReach: segmentación de clientes de restaurantes

Integración de la base de clientes con datos de Yelp, análisis y propuestas de segmentación

Autora: Laura Garmendia · Carpeta del proyecto: ProyectoM1_LauraGarmendia · Octubre de 2026

1. Contexto

InsightReach es una empresa de marketing digital especializada en campañas personalizadas para negocios locales. Con el crecimiento de su base de clientes y la expansión a nuevos mercados, busca optimizar su estrategia de segmentación para mejorar la efectividad de sus campañas.

Este proyecto es un **análisis de datos** sobre su base de **30.000 clientes de restaurantes en 10 ciudades de EE. UU.** Se eligió **Chicago**, se limpiaron y transformaron los datos, se integraron con la **oferta real de restaurantes de la ciudad obtenida de la API de Yelp** y se analizaron para generar recomendaciones de segmentación.

2. Objetivos

Objetivo general: responder a **qué clientes dirigir cada campaña de marketing y con qué propuesta**, con recomendaciones fundadas en los datos.

Objetivos específicos:

- Explorar la estructura y la calidad de la base de clientes, y limpiarla justificando cada decisión.
- Enriquecer el análisis con la oferta de restaurantes de la ciudad, obtenida de la API de Yelp.
- Responder las preguntas del negocio con visualizaciones y análisis estadístico.
- Proponer segmentos de clientes accionables y una estrategia para cada estrato socioeconómico, documentando el proceso de forma reproducible.

3. Recorrido del proyecto: pasos y resultados

Paso	Qué se hizo	Resultado	Dónde
1. Diagnóstico	Exploración de la base original: estructura, tipos, nulos, duplicados, rangos, outliers y coherencia entre variables.	Errores de carga sistemáticos (edades -5 y 300, visitas -3); 34 % de los registros con algún problema.	EDA, secc. 2-4
2. Limpieza y transformación	Filtro de Chicago, valores imposibles a nulo, imputación por grupo, corrección de tipos.	5.384 clientes sin nulos: <code>clientes_chicago_limpio.csv</code> .	EDA, secc. 5-9
3. Integración con Yelp	Conexión a la API, una búsqueda por preferencia alimenticia, limpieza y unión por preferencia y nivel de precio.	920 restaurantes; 83 % de los clientes con oferta afín y 392 sin oferta: <code>clientes_chicago_enriquecido.csv</code> .	API Yelp
4. Análisis de negocio	Misma limpieza aplicada a las 10 ciudades; nueve preguntas del negocio; correlaciones totales y por estrato.	El estrato explica frecuencia y gasto; Chicago visita igual pero gasta menos por visita.	EDA, secc. 11-12
5. Segmentación	Cruce del perfil de los clientes con la oferta de Yelp.	Cinco grupos de clientes con su peso en clientes y en gasto.	EDA, secc. 13-14

Paso	Qué se hizo	Resultado	Dónde
6. Recomendaciones	Campaña principal, estrategia por estrato, acciones por segmento, priorización y plan.	Propuestas fundadas en los hallazgos.	Recomendaciones.pdf

4. Fuentes de datos

Fuente	Descripción	Volumen
Base de clientes (CSV provisto por la empresa)	Datos demográficos, socioeconómicos y de consumo: edad, género, ciudad, estrato, ingresos, frecuencia de visita, gasto promedio por comida, preferencias alimenticias, consumo de licor, membresía y medio de pago.	30.000 clientes, 17 columnas, 10 ciudades de EE. UU.
Yelp Places API (antes Yelp Fusion)	Restaurantes de Chicago: nombre, categorías, calificación, cantidad de reseñas, nivel de precio y ubicación.	950 negocios descargados; 920 tras la limpieza
Tendencia externa	Informe del Good Food Institute sobre el consumidor plant-based en el sector gastronómico de EE. UU. (agosto de 2026).	Usado para respaldar las recomendaciones

5. Estructura de la carpeta del proyecto

ProyectoM1_LauraGarmendia/		
├── AVANCES/		
│ ├── Avance_EDA_Laura_Garmendia.ipynb		Avances 1 y 3
│ └── Avance_API_Yelp_Laura_Garmendia.ipynb		Avance 2
├── ARCHIVOS/		
│ ├── base_datos_restaurantes_USA_v2.csv		Base original (entrada)
│ ├── clientes_chicago_limpio.csv		Salida del Avance 1
│ ├── yelp_chicago_raw.json		Respuesta cruda de la API (caché)
│ ├── yelp_chicago_negocios.csv		Restaurantes de Yelp limpios
│ └── clientes_chicago_enriquecido.csv		Clientes + oferta de Yelp
├── DOCUMENTACION/		
│ ├── README.pdf		Este documento
│ └── Recomendaciones.pdf		Propuestas de segmentación

Los notebooks leen y guardan los datos en la carpeta **ARCHIVOS** mediante una ruta relativa (**CARPETA_DATOS** = `"../ARCHIVOS"`, definida en la celda de parámetros de cada notebook). Por eso hay que conservar esta estructura de carpetas.

6. Cómo ejecutar el proyecto

1. Instalar Python 3 y las librerías pandas, numpy, matplotlib, seaborn y requests (se trabajó con Jupyter Notebook en VS Code).
2. Descargar la carpeta completa del proyecto (conservando su estructura) y abrir los notebooks de **AVANCES** en Jupyter o VS Code.
3. Los archivos intermedios ya están incluidos en **ARCHIVOS**, así que cada notebook puede ejecutarse directamente con Run All.
4. El notebook del Avance 2 usa `yelp_chicago_raw.json` como caché y **no necesita API key**. Para descargar datos nuevos, borrar ese archivo e ingresar una clave propia cuando se solicite (se pide de forma oculta y nunca queda escrita en el código).

Para regenerar todo desde cero: ejecutar el Avance EDA hasta la sección 9 (genera los clientes limpios), luego el Avance API Yelp (genera los clientes enriquecidos) y por último el Avance EDA completo. Para analizar otra ciudad alcanza con cambiar la variable **CIUDAD**.

7. Criterios de trabajo

Criterios generales que guiaron las decisiones en todo el proyecto:

1. **Entender antes de corregir:** el diagnóstico se hizo sobre la base original intacta, y se trabajó con una copia del DataFrame por etapa (base → limpia → trans) para poder auditar cada cambio.
2. **No eliminar registros:** los errores estaban en columnas puntuales; borrar filas habría reducido y sesgado la muestra.
3. **No inventar datos personales:** la preferencia faltante quedó como “No informado”, el contacto como “Dato no cargado” y el precio faltante de Yelp no se imputó.
4. **Imputar con la mediana del grupo** (género o estrato) y **después de filtrar la ciudad**, para respetar las diferencias reales entre clientes.
5. **Segmentar antes de juzgar:** los outliers se evaluaron dentro de cada estrato, y las correlaciones se calcularon también por estrato antes de sacar conclusiones.
6. **Verificar en lugar de suponer:** controles con `assert` en la limpieza de las 10 ciudades, en la unión con Yelp y al cargar la base enriquecida.
7. **Reproducibilidad y orden:** parámetros en una sola celda, rutas relativas, caché de la API, API key fuera del código y nombres congruentes de principio a fin (`df_` + origen + etapa + alcance).

8. Funciones creadas

El código repetido se reunió en funciones, para aplicar siempre el mismo criterio y no duplicar líneas:

Función	Notebook	Qué hace
<code>tabla_frecuencias</code>	EDA	Cantidad y porcentaje de cada categoría de una columna.
<code>resumen_nulos</code>	EDA y API	Cantidad y porcentaje de nulos por columna.
<code>tabla_cruzada</code>	EDA y API	Porcentaje de cada categoría de una variable dentro de otra (cada fila suma 100).
<code>porcentaje_si</code>	EDA	Porcentaje de respuestas “Sí” (licor, membresía).
<code>limites_iqr</code>	EDA	Límites del método IQR para detectar outliers, global y por estrato.
<code>limpiar_base</code>	EDA	Aplica toda la limpieza del Avance 1 a cualquier conjunto de ciudades; verificada con <code>assert</code> contra Chicago.
<code>colores_destacando</code>	EDA	Colores de los rankings, con la ciudad analizada resaltada.
<code>resumir_segmento</code>	EDA	Indicadores clave de un segmento: tamaño, gasto, visitas, membresía, contacto y oferta.
<code>obtener_api_key</code>	API	Lee la API key de una variable de entorno o la pide de forma oculta.
<code>armar_encabezados</code>	API	Arma el encabezado de autenticación (Bearer).
<code>probar_conexion</code>	API	Hace una petición de prueba y muestra el código de estado HTTP.
<code>buscar_negocios</code>	API	Descarga negocios de Yelp con paginación, pausas y manejo de errores.
<code>aplanar_negocio</code>	API	Convierte cada negocio (JSON anidado) en una fila de tabla.

9. Avance 1: exploración y limpieza

9.1 Metodología

Se trabajó con una copia del DataFrame por etapa, para que cada paso quede separado, se pueda auditar y siempre se pueda volver al dato original:

DataFrame	Etapas
df_restaurantes_base	Lectura del CSV sin modificaciones. Sobre él se hizo todo el diagnóstico.
df_restaurantes_limpia	Filtrado de la ciudad y marcado de los valores imposibles como nulos (no se inventa ningún dato).
df_restaurantes_trans	Imputación de nulos y corrección de tipos. Es el dataset final del avance.

9.2 Problemas detectados y decisiones

Variable	Problema	Decisión y justificación
edad	101 nulos; 97 valores -5 y 110 valores 300 (valores centinela de carga); tipo float sin decimales reales.	Marcar como nulos e imputar con la mediana por género dentro de la ciudad. Convertir a entero.
frecuencia_visita	1.547 valores -3. Esos clientes sí registran gasto: el dato se perdió.	Imputar con la mediana por estrato , porque cada estrato tiene su propio rango de visitas.
promedio_gasto_comida	145 nulos. El IQR global marca unos 1.370 outliers, pero por estrato no hay ninguno.	No eliminar outliers: son clientes de estrato Muy Alto. Gasto 0 si no visita; si no, mediana por estrato.
preferencias_alimenticias	1.403 nulos (4,7 %).	Categoría " No informado " en lugar de la moda: imputar "Carnes" inventaría una preferencia personal.
teléfono / correo	Cerca del 50 % de nulos en cada uno; 454 correos compartidos.	Leyenda "Dato no cargado".
Tipos de datos	id_persona como número; categóricas como texto.	id a texto (es un identificador); categóricas a category, con el estrato ordenado.
Duplicados	0 filas idénticas, 0 ids repetidos, 10 pares de homónimos.	Ningún registro eliminado.

Ciudad elegida: Chicago, la de más clientes (5.384, 18 %): más muestra, grupos más estables para segmentar y amplia oferta en Yelp. La ciudad se filtró antes de imputar para que las medianas reflejen a sus clientes.

10. Avance 2: integración con la API de Yelp

10.1 Metodología

1. **Conexión:** petición GET al endpoint de búsqueda de negocios con autenticación Bearer; verificación con el código de estado HTTP (200).
2. **Extracción por preferencia:** una búsqueda por cada preferencia alimenticia de los clientes, para que los datos externos queden conectados con la base desde el origen.
3. **Paginación y límites:** 50 resultados por petición y 240 por búsqueda, resueltos con el parámetro offset, pausas y manejo de errores. Se guardó el total real de negocios de cada rubro.
4. **Limpieza:** solo negocios de la ciudad de Chicago, sin cerrados ni duplicados, categorías repetidas corregidas, calificación 0 tratada como "sin calificación" (la escala de Yelp va de 1 a 5, y dejarla en 0 bajaba los promedios) y precio convertido a nivel 1-4. El precio faltante (37 %) no se imputó.

5. **Integración:** como cliente y restaurante no comparten identificador, se construyeron dos variables puente (preferencia y nivel de precio) y se unieron con un merge de tipo left, sin perder clientes.

10.2 Resultados

Preferencia	% clientes	% oferta Yelp	Restaurantes (total Yelp)	Cientes cada 100 restaurantes
Vegetariano	24,8	5,6	60	1.872
Vegano	12,6	6,2	67	852
Carnes	35,1	27,3	293	542
Pescado	12,1	25,9	278	196
Mariscos	15,4	34,9	374	186

El **83 %** de los clientes tiene oferta afín a su preferencia y su presupuesto. **392 clientes** vegetarianos y veganos de estratos Alto y Muy Alto no tienen oferta en su rango de precio. Los niveles \$ y \$\$\$ tienen menos oferta que clientes; el \$\$ está sobreofertado.

11. Avance 3: análisis final y recomendaciones

La limpieza se aplicó a las 10 ciudades con `limpiar_base`, se creó la variable **gasto mensual** (gasto por comida × visitas por mes), porque las preguntas del negocio se refieren al gasto mensual y la base solo informa el gasto por comida y la frecuencia, y se calcularon correlaciones de **Pearson** (relación lineal) y **Spearman** (basada en rangos, menos sensible a valores extremos) en el total y **dentro de cada estrato**: una correlación que desaparece dentro de los estratos indica que la relación la produce el estrato y no la variable analizada.

11.1 Preguntas del negocio y respuestas

Pregunta	Respuesta
¿Cuántos clientes hay por ciudad?	Chicago (5.384) y NYC (4.769) reúnen un tercio de la base; Phoenix es la más chica (1.511).
¿Cómo se distribuyen los estratos?	Medio 31 %, Alto 30 %, Bajo 21 %, Muy Alto 18 %. Miami y San Diego tienen mayoría de estratos altos.
¿Dónde se gasta más al mes en restaurantes?	Miami (227 USD) lidera; Chicago (139 USD) es anteúltima. La frecuencia es igual en todas las ciudades: cambia el gasto por visita.
Frecuencia vs. gasto por comida, según estrato	Correlación de 0,61 en el total, pero cercana a 0 dentro de cada estrato: el estrato explica ambas variables.
Ingresos vs. gasto mensual	Relación fuerte (Pearson 0,71; Spearman 0,81) que también desaparece dentro de cada estrato. Se destina cerca del 3 % del ingreso a restaurantes.
Preferencias por ciudad	Carnes (26 %) y vegetariano (22 %) lideran. Miami prefiere mariscos; Boston y Seattle, vegetariano.
Perfil de los clientes de mayor gasto	Top 10 % (más de 424 USD por mes): 96 % Muy Alto, 95 % premium, 8 visitas por mes, 90 USD por comida. Comen lo mismo que el resto.
¿Qué ciudad paga más membresías?	En cantidad, Chicago (2.215); en proporción, Miami (53 %). La tasa depende de cuántos clientes de estrato alto tiene cada ciudad.
Consumo de licor y edad	Va por escalones: 90 % de 18 a 30 años, 50 % de 31 a 55, 70 % de 56 a 70 y 40 % desde los 71. El estrato no influye.

11.2 Segmentos propuestos (Chicago)

Los segmentos se definieron a partir de los hallazgos, con criterios simples y reproducibles. En el notebook se identifican con letras (A a E); en las Recomendaciones, con nombres pensados para el cliente.

Grupo (segmento en el notebook)	Criterio de definición	Tamaño y valor	Por qué se definió así
1. Vegetarianos y veganos de alto gasto sin oferta (A)	<code>estado_oferta</code> = "Sin oferta en su rango de precio"	392 clientes · 15 % del gasto	En Yelp no hay restaurantes veganos \$\$\$ o \$\$\$\$ y solo uno vegetariano \$\$\$\$; demanda de alto valor sin atender.
2. Clientes de mayor valor (B)	Estrato Muy Alto	17 % de clientes · 50 % del gasto	El top 10 % de gasto es 96 % Muy Alto: el valor se concentra en este estrato.
3. Estrato Medio sin membresía premium (C)	Estrato Medio y sin membresía	1.563 clientes · 13 % del gasto	Grupo más numeroso con baja adhesión (13 %); los miembros del Medio gastan igual que los no miembros.
4. Jóvenes de 18 a 30 años (D)	Edad ≤ 30	21 % de clientes · 21 % del gasto	El consumo de licor depende de la edad (90 % de 18 a 30), no del estrato.
5. Clientes de bajo presupuesto (E)	Estrato Bajo con frecuencia > 0	887 clientes · 2 % del gasto	El nivel \$ tiene poca oferta (28 % de clientes vs. 11 % de restaurantes).

Las acciones de cada grupo (perfil, campaña, canal, mensaje y métrica), la estrategia por estrato, la priorización y el plan de implementación están en **Recomendaciones.pdf**.

12. Calidad de los datos

El 34 % de los registros tenía algún dato faltante o erróneo, con errores de carga sistemáticos (edades de -5 y 300, visitas de -3). Imputar solo estima el dato: se recomienda a la empresa **validar los datos al cargarlos**, no usar valores centinela y definir campos obligatorios.

13. Conclusiones

Respuesta a la pregunta del proyecto (a qué clientes dirigir cada campaña y con qué propuesta): la campaña principal debe apuntar a la **alta gama**, reteniendo al estrato Muy Alto y abriendo oferta vegetariana y vegana para los clientes de alto gasto que hoy no la tienen. Al resto de los estratos se llega subiendo el gasto por visita en el Alto, con salidas más completas y membresía en el Medio, y con oferta económica en el Bajo, con las bebidas dirigidas por edad. Se apoya en estos hallazgos:

1. **El estrato socioeconómico ordena todo el comportamiento de consumo.** Las relaciones aparentes entre frecuencia, ingreso y gasto desaparecen dentro de cada estrato.
2. **El valor está concentrado:** en Chicago, el 17 % de los clientes genera la mitad del gasto, y 392 vegetarianos y veganos de alto gasto no tienen oferta acorde.
3. **Chicago es el mercado más grande, pero con uno de los gastos por visita más bajos:** con el mismo ingreso y las mismas visitas, el estrato Medio gasta 17,5 USD por comida contra 25,5 USD en las otras ciudades. La oportunidad es aumentar el gasto por visita.

Limitaciones: gasto mensual estimado, oferta vegetal de Yelp probablemente subestimada y patrones que sugieren datos generados por reglas: las recomendaciones deben validarse con pruebas piloto.